

# Universidad de Costa Rica

Facultad de Ingeniería Escuela de Ingeniería Eléctrica



IE-0217 Estructuras abstractas de datos y algoritmos para ingeniería.

# Laboratorio 2: Compresión de Texto

Belinda Brown Ramírez - B61254

# I-2019

| Tabla de contenidos |  |              |
|---------------------|--|--------------|
| 1.                  | Enunciado  | 2            |
| 2.                  | Pruebas:         2.1. C++:          2.2. Python:                 | 2            |
| 3.                  | Conclusiones:  | 6            |
| 4.                  | Diagramas de clase   | 6            |
| 5.                  | Anexos           5.1. Código C++:            5.2. Código Python: | 7<br>7<br>13 |
| 6.                  | Consideraciones  | <b>1</b> 4   |

### 1. Enunciado

En este laboratorio su equipo de trabajo deberá implementar, en Python y C++, un algoritmo de compresión y descompresión de texto basado en reemplazos. Dicho algoritmo funciona de la siguiente manera:

- Tomando como entrada un archivo con texto, se establece un umbral de reemplazo.
- Para cada palabra cuya frecuencia sea igual o mayor a la del umbral de reemplazo, cambiar su hilera de caracteres por otra. Agregue en un archivo aparte una tabla con cada uno de los reemplazos, indicando la palabra original y su nueva hilera.

No modifique el archivo de entrada, cree uno nuevo con el mismo nombre que el original pero de extensión .rep y el archivo de la tabla, de la misma manera pero con extesión .tab.

Haga un programa de prueba para los ítemes anteriores que utilice tamaños de entrada diferentes, con archivos de 1MB, 10MB, 100MB y 1000MB (este de ser posible). Tome los tiempos de ejecución de ambas implementaciones con todos los tamaños de archivos y grafíquelos. Hipotetice sobre el por qué de la tendencia de los tiempos.

En la medida de los posible utilice programación orientada a objetos (ej. una clase para reemplazar, otra para manejar la entrada/salida, etc.).

### 2. Pruebas:

## 2.1. C++:

```
Archivo Editar Ver Buscar Terminal Ayuda
at reemplazo: 63
at reemplazo: 63
nisi reemplazo: 55
Fusce reemplazo: 65
rusce reemplazo: 69
non reemplazo: 68
mauris reemplazo: 69
nisi reemplazo: 61
nisi reemplazo: 620
nisi reemplazo: 620
nisi reemplazo: 620
nc reemplazo: 626
Nulla reemplazo: 626
Nulla reemplazo: 636
Nulla reemplazo: 636
moltis reemplazo: 636
moltis reemplazo: 647
moltis reemplazo: 648

Sed reemplazo: 649
Donac reemplazo: 649
Donac reemplazo: 658
vel reemplazo: 658
vel reemplazo: 658
vel reemplazo: 658
vel reemplazo: 680
vel reemplazo: 680
vel reemplazo: 681
loctus reemplazo: 680
vel reemplazo: 681
loctus reemplazo: 683
at reemplazo: 683
at reemplazo: 685
vel reemplazo: 686
bliendur reemplazo: 681
loctus reemplazo: 683
at reemplazo: 686
loctus reemplazo: 619
ac reemplazo: 619
ac reemplazo: 617
rurum reemplazo: 6136
finibus reemplazo: 6136
finibus reemplazo: 6137
rurum reemplazo: 6136
finibus reemplazo: 6137
rurum reemplazo: 6139
loctus reemplazo: 6142
amet reemplazo: 6136
finibus reemplazo: 6139
loctus reemplazo: 6142
amet reemplazo: 6136
loctus reemplazo: 6142
amet reemplazo: 6145
loctus reemplazo: 6150
loct
```

```
Archivo Editar Ver Buscar Terminal Ayuda
gravida, reemplazo: 6421
usismod, reemplazo: 6422
nisl, reemplazo: 6423
nharetra, reemplazo: 6424
commodo, reemplazo: 6425
nate: reemplazo: 6426
ante: reemplazo: 6427
facilisis, reemplazo: 6428
dolor, reemplazo: 6438
dolor, reemplazo: 6439
laoret, reemplazo: 6431
dolor, reemplazo: 6431
dolor, reemplazo: 6433
pellentesque, reemplazo: 6433
pellentesque, reemplazo: 6438
molestie, reemplazo: 6436
venenatis, reemplazo: 6437
vt. reemplazo: 6438
ullamcorper, reemplazo: 6437
vt. reemplazo: 6448
turpis, reemplazo: 6449
facults, reemplazo: 6446
furpis, reemplazo: 6446
furpis, reemplazo: 6446
furpis, reemplazo: 6447
moutis, reemplazo: 6446
mollis, reemplazo: 6446
furpis, reemplazo: 6446
mollis, reemplazo: 6447
moutis, reemplazo: 6446
mollis, reemplazo: 6446
mollis, reemplazo: 6446
mollis, reemplazo: 6456
mollis, reemplazo: 6457
moutis, reemplazo: 6458
mollis, reemplazo: 6458
mollis, reemplazo: 6458
mollis, reemplazo: 6456
```

```
Archivo Editar Ver Buscar Terminal Ayuda

Esmirna reemplazo: 6165345

Silvano, reemplazo: 6165341

[Stelger], reemplazo: 6165491

[Stelger], reemplazo: 6165491

[Stelger], reemplazo: 6165969

Cirilo reemplazo: 6167967

Primara, reemplazo: 6167967

Primara, reemplazo: 6167967

Primara, reemplazo: 6167968

—Grigo, reemplazo: 6167983

Domiciano, reemplazo: 6167983

Domiciano, reemplazo: 6169830

Andreas reemplazo: 6169830

Andreas reemplazo: 6169867

Revelación reemplazo: 6178067

Revelación reemplazo: 6170867

Revelación reemplazo: 6170868

Revemplazo: 6171868

Revemplazo: 61718788

Revemplazo: 6172888

Revemplazo: 6172888

Revemplazo: 6172888

Revemplazo: 6172888

Revemplazo: 6172888

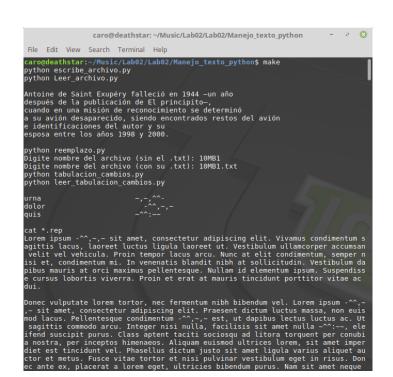
Revemplazo: 6172888

Revemplazo: 6174888

Revempla
```

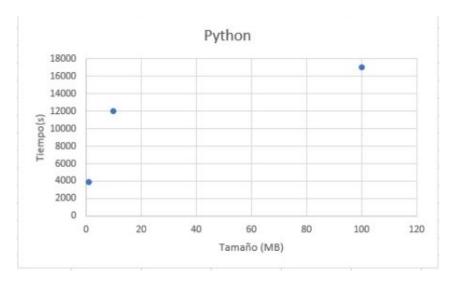
## 2.2. Python:

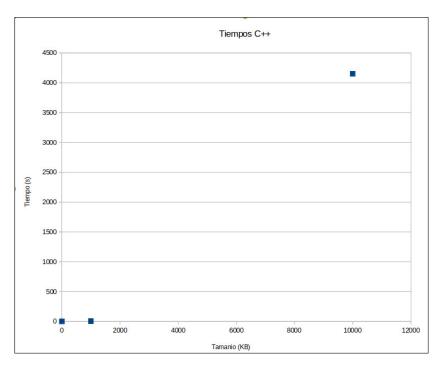




# 3. Conclusiones:

Las instrucciones indican que se debe realizar una comparación entre ambos lenguajes, por tanto tenemos:





Con respecto a las gráficas podemos observar como al utilizar un lenguaje compilado como C++, el tiempo de espera es menor en comparación con el lenguaje interpretado Python.

# 4. Diagramas de clase

Se encontrarán adjuntos en refman.pdf. Creado por Doxygen, ubicado en la carpeta DOXY latex.

#### 5. Anexos

# 5.1. Código C++:

main.cpp:

```
/*!
       *\author Ruben Venegas , Carolina Urrutia , Belinda Brown
2
3
      *\version 1.0
      *\date 11/05/2019
4
5
      *\mainpage Compresion de texto
      *\section intro_sec Introduccion
6
       * Este codigo reemplaza palabras segun la cantidad de recurrencias que presente
      la palabra
      */
9
10
11 #include <iostream>
12 #include "reemplazo.h"
  #include "creartab.h"
15
  using namespace std;
16
  int main(int argc , char* argv[]) {
17
18
19
      CrearTab tab1(argv[2], atoi(argv[1]));
20
      int lineas = tab1.creacion_tab();
      Reemplazo remp1(argv[2],"in.tab", lineas);
21
      remp1.reemplazar();
22
      cout << "Se reemplazaron: " << lineas << " palabras" << endl;</pre>
23
24
      cout << "Desea descomprimir el archivo ? s/n" << endl;
      string entrada;
26
       cin >> entrada;
27
       if (entrada == "s"){
28
          remp1.descomprimir();
29
          cout << "El archivo descomprimido se llama in-des.rep" <<endl;</pre>
30
      }
31
32
33
      return 0;
35 }
1 #ifndef CREARTAB_H
2 #define CREARTAB_H
4 #include <iostream>
5 #include <fstream>
6 #include <cstring>
7 #include <sstream>
8 #include <string>
10
11
  using namespace std;
  class CrearTab {
13
      public:
14
           string filePath;
           int umbral;
```

```
17
           CrearTab();
18
           CrearTab(string filePath, int umbral);
19
20
           int count_words(int longitud, string entrada);
           int frecuencia_palabra(string* palabras, int* frecuencia, int num, string
21
      word);
           int creacion_tab();
       };
23
24 #endif
1 #include "creartab.h"
  using namespace std;
5
  CrearTab::CrearTab(){};
  CrearTab::CrearTab(string filePath, int umbral){
       cout << "\t\t\t: "<< filePath << " - " << umbral << endl;
10
12
       this -> file Path = file Path;
       this -> umbral=umbral; };
  int CrearTab::count_words(int longitud, string entrada){ //cuenta las palabras en un
14
       string
       int i=0;
16
       int cont = 0;
17
       while (i < longitud) {
           while (i < longitud && entrada[i] == '') {
18
                i = i + 1;
19
20
           if (i < longitud) {
21
                cont = cont + 1;
           while (i < longitud && entrada [i]!=',') {
24
                i = i + 1;
           }
26
27
       return cont;
28
29
30
  int CrearTab:: frequencia_palabra (string* palabras, int* frequencia, int num, string
      word){
       bool condicion=false;
31
       if (num==0){ //Llena el primer elemento del arreglo con la primer palabra
32
           palabras [num]=word;
33
           frecuencia [num] = frecuencia [num] + 1;
34
           num=num+1;
36
37
       for (int i=0; i \le num; i++)
38
           if (palabras[i]==word && num>0){
39
                frecuencia [i]=frecuencia [i]+1; //Si la palabra ya estaba guardada,
40
      aumenta su frecuencia
41
                condicion=true;
42
43
       if (condicion = false && num>0) {
44
           palabras [num]=word; //Si la palabra no es repetida la guarda
45
           frecuencia [num] = frecuencia [num] + 1;
```

```
num=num+1;
47
48
49
50
      num=num;
       return num;
53
54
  int CrearTab::creacion_tab(){
       int count =0;
56
       ifstream archivol;
57
       archivol.open(filePath, ios::in);
       string texto1;
58
       while (!archivo1.eof()){
           getline(archivo1, texto1); //Divide el texto en lineas
60
           int k = count_words(texto1.length(), texto1); //por cada linea cuenta las
61
      palabras
           count=count+k; //contador de palabras totales del texto
62
63
      cout<<" Palabras contadas: "<<count<<endl;</pre>
64
       string palabras [count] {}; //crea un arreglo de strings con la cantidad de
      palabras tot del texto
       int frecuencias [count] {}; //crea un arreglo de ints con la cantidad de palabras
       tot del texto que se
                                    //asociara a cada string del arreglo anterior (
67
      contara la frecuencia de cada palabra)
       archivo1.close();
68
      ifstream archivo2;
       archivo2.open(filePath, ios::in);
70
       string texto2;
       int m = 0;
72
       int num=0;
73
       int otra = 0;
74
       while (!archivo2.eof()){
           getline (archivo2, texto2);
76
           istringstream isstream (texto2);
           bool condicion = false;
79
           while (!isstream.eof()) { //divide cada linea en palabras
               string tempStr;
80
               isstream >> tempStr;
81
               otra = otra +1;
82
               if (otra > 10000){
83
                   cout << "Creando in.tab, Voy revisando 10000 mas" << endl;
84
85
86
               if (num<count && tempStr != "." && tempStr != "," ){ //se guarda cada
87
      palabra en el arreglo creado anteriormente
                   int m = frecuencia-palabra(palabras, frecuencias, num, tempStr);
88
                   num=m;
89
91
           }
92
       archivo2.close();
       int cant_entradas = 0 ;
94
       ofstream salida;
95
       salida.open("in.tab", ios::ate); //se usa ios::ate para escribir desde la ultima
96
       parte del texto
       for (int j=0; j<\text{count}; j++)
97
           if (frecuencias [j]>=umbral && palabras [j] !="") { //solo escribe las palabras
98
       que superen el rango de frecuencias
```

```
cout << palabras[j]<< " freq:" << frecuencias[j]<< " &"<<j<<endl;
99
                salida \ll palabras[j] \ll "freq:" \ll frecuencias[j] \ll \&" \ll j \ll endl;
100
                cant_entradas = cant_entradas +1;
103
104
       salida.close();
       return cant_entradas; //cantidad de lineas escritas en in.tab
106
107
 1 #ifndef REEMPLAZO_H
 2 #define REEMPLAZO_H
 4 #include <iostream>
 5 #include <fstream>
 6 #include <cstring>
 7 #include <sstream>
 8 #include <string>
10
```

using namespace std;

```
12
  class Reemplazo {
      public:
14
           string filePath;
16
           string tab_path;
17
           int entradas;
           Reemplazo(string filePath, string tab_path, int entradas);
19
           void reemplazar();
20
           void descomprimir ();
21
           Reemplazo();
23
           };
26 #endif
1 #include "reemplazo.h"
2
  Reemplazo::Reemplazo(string filePath, string tab_path, int entradas){
      this->filePath=filePath; //direction de in.txt
      this->entradas=entradas; //cantidad de lineas en in.tab
      this->tab_path=tab_path; //direction de in.tab
6
      };
```

```
void Reemplazo::reemplazar(){
      ifstream archivo1;
10
      archivol.open(tab_path, ios::in);
12
      string texto1;
      string palabras[entradas] {}; //arreglo donde se guardaran las palabras a
      reemplazar guardadas en in.tab
      string reemplazos[entradas] {}; //arreglo donde se guardaran las palabras de
14
      reemplazo guardadas en in.tab
15
      int iter = 0;
      int otro = 0;
16
      while (!archivo1.eof()) {
17
           getline(archivo1, texto1);
           istringstream isstream(texto1);
19
           int k = 0;
```

```
while (!isstream.eof()) {
21
22
               string tempStr;
23
               isstream >> tempStr;
24
               if (k ==0 && iter<entradas && tempStr != "." && tempStr != "," ){
                    palabras[iter]=tempStr; //va guardando en un arreglo las palabras a
25
      reemplazar guardadas en in.tab
26
               if (k==2 && iter<entradas && tempStr != "." && tempStr != "," ){
27
                   reemplazos[iter]=tempStr; //va guardando en un arreglo las palabras
      de reemplazo guardadas en in.tab
29
               k=k+1;
30
31
           iter=iter+1; //lleva el conteo de las palabras totales
32
           int otro = otro +1;
33
34
           if (iter = 10000)
               cout << "Llevo revisando 10000 palabras mil m s" << endl;
35
36
           }
37
38
      }
39
40
       archivol.close();
41
42
       cout << "palabras a reemplazar: " << endl;
43
       for (int i=0; i<entradas; i++){
           cout<<palabras[i]<< " reemplazo: "<< reemplazos[i] << endl;</pre>
44
45
       ifstream archivo2;
46
       archivo2.open(filePath, ios::in);
47
       string texto2;
48
       ofstream salida;
49
       salida.open("in.rep", ios::ate);
       while (! archivo2 . eof()) {
           getline (archivo2, texto2); //divide el texto en lineas
           istringstream isstream (texto2);
53
           string nuevo = \{\};
           while (!isstream.eof()) { // divide las lineas en palabras
               string tempStr;
56
               isstream >> tempStr;
               for (int j=0; j < \text{entradas}; j++){
58
                    if (tempStr==palabras[j] && tempStr != " . " && tempStr != " , " ){
                        tempStr=reemplazos[j]; //va comparando si la palabra debe ser
60
      guardada
                    }
61
               nuevo.append(tempStr); //se agrega cada palabra para formar la linea
               nuevo.append(" ");
64
65
           salida << nuevo << endl; //se escribe cada linea del texto con las palabras
      cambiadas
67
       archivo2.close();
       salida.close();
70 }
71
  void Reemplazo::descomprimir () {
72
       ifstream archivo1;
73
       archivol.open(tab_path, ios::in);
74
      string texto1;
```

```
string palabras [entradas] \{\}; //arreglo donde se guardaran las palabras a
       reemplazar guardadas en in.tab
77
       string reemplazos [entradas] {}; //arreglo donde se guardaran las palabras de
       reemplazo guardadas en in.tab
78
       int iter = 0;
       int otro =0;
79
       while (! archivo1 . eof()) {
80
            getline (archivo1, texto1);
81
            istringstream isstream (texto1);
            int k = 0;
84
            while (!isstream.eof()) {
                string tempStr;
85
86
                isstream >> tempStr;
                if (k ==2 && iter < entradas && tempStr != "." && tempStr != "," ){
87
                    palabras[iter]=tempStr; //va guardando en un arreglo las palabras a
88
       reemplazar guardadas en in.tab
89
                if (k==0 && iter < entradas && tempStr != "." && tempStr != "," ){
90
                    reemplazos[iter]=tempStr; //va guardando en un arreglo las palabras
91
       de reemplazo guardadas en in.tab
92
93
                k=k+1;
            iter=iter+1; //lleva el conteo de las palabras totales
95
            int otro = otro +1;
96
97
            if (iter = 10000)
                cout << "Llevo revisando 10000 palabras mil m s" << endl;
98
                otro =0;
99
            }
100
       }
102
       archivol.close();
104
       cout << "palabras a reemplazar: " << endl;
105
       for (int i=0; i<entradas; i++){
106
            cout<<palabras[i]<< " reemplazo: "<< reemplazos[i] << endl;</pre>
108
       ifstream archivo2;
       archivo2.open(filePath, ios::in);
       string texto2;
       ofstream salida;
112
       salida.open("in-des.rep", ios::ate);
113
       while (! archivo2 . eof ()) {
114
            getline (archivo2, texto2); //divide el texto en lineas
115
            istringstream isstream (texto2);
            string nuevo = \{\};
117
            while (!isstream.eof()) { // divide las lineas en palabras
118
                string tempStr;
                isstream >> tempStr;
                for (int j=0; j<entradas; j++){
                    if (tempStr=palabras[j] && tempStr != " . " && tempStr != " , " ){
                         tempStr=reemplazos[j]; //va comparando si la palabra debe ser
       guardada
                    }
124
                nuevo.append(tempStr); //se agrega cada palabra para formar la linea
126
                nuevo.append(" ");
127
128
            salida << nuevo << endl; //se escribe cada linea del texto con las palabras
```

# 5.2. Código Python:

```
1 \# -*- coding: utf-8 -*-
2
3 #Writting first part
4 archivo = open("Historia_principito.txt", "w")
6 archivo.write("\n")
7 archivo.write ("Antoine de Saint Exupry falleci en 1944 un a o\n")
8 archivo.write ("despu s de la publicaci n de El principito ,\n")
9 archivo.write("cuando en una misi n de reconocimiento se determin \n")
10 archivo.write ("a su avi n desaparecido, siendo encontrados restos del avi n\n")
archivo.write("e identificaciones del autor y su\n")
archivo.write("esposa entre los a os 1998 y 2000.\n")
archivo.write("\n")
14 archivo.close()
2 archivo = open("Historia_principito.txt", "r")
3 for linea in archivo:
    hilera = linea.replace("\n","")
    print(hilera)
6 archivo.close()
archivo = open ("Tabla_Cambios.tab", "r")
2 for linea in archivo:
    hilera = linea.replace("\n","")
    print(hilera)
5 archivo.close()
1 import re
2 import numpy
3 import os
4 import sys
8 replacements = {"urna":"~,~,^,-", "dolor":"-^^,,~", "quis":"-^^:-"}
10 file_a_leer = raw_input("Digite nombre del archivo (sin el .txt): ")
  file_a_leer+=".rep"
12
  fname = raw_input("Digite nombre del archivo (con su .txt): ")
13
14
name = open (fname, 'r')
16
with name as infile, open(file_a_leer, "w") as outfile:
    for line in infile:
          for src, target in replacements.items():
```

```
line = line.replace(src, target)
          outfile.write(line)
22 # ##archivo = name.read()
23 # ##divide = archivo.split()
25 # ##frecuenciaPalab = [divide.count(w) for w in divide]
27 # with name as infile, open(file_a_leer, "w") as outfile:
while line in infile:
29 # ##
            while frecuenciaPalab > 3:
30 #
           for src, target in replacements.items():
               line = line.replace(src, target)
31 #
       outfile.write(line)
1 \# -*- coding: utf-8 -*-
3 #Writting first part
4 archivo = open("Tabla_Cambios.tab", "w")
6 archivo.write("\n")
                                          7 archivo.write ("urna
8 archivo. write ("dolor
9 archivo.write("quis
archivo.write("\n")
12 archivo.close()
```

### 6. Consideraciones

- 1. Equipos de 2 o 3 personas.
- 2. Genere un reporte en LATEXque incluya el enunciado, el diagrama de clases, sus conclusiones y, como anexo incluya su código fuente
- 3. Suba su código y documentación (doxygen, README, INSTALL) al GitLab respectivo de su grupo y el directorio del laboratorio.
- 4. Cada estudiante debe subir el reporte a Schoology.
- 5. Recuerde que por cada día tardío de entrega se le rebajaran puntos de acuerdo con la formula:  $4^d$  donde d>1 es la cantidad de días tardíos